

Proposta de Desenvolvimento de Sistema Inteligente de Gestão Clínica NF-IPO Lisboa

Substituição dos Ficheiros Excel na Gestão Clínica NF-IPO Lisboa

Relatório concebido usando Inteligência Artificial: Anthropic Claude Opus

Destinatário: Equipa clínica NF-IPO Lisboa

Data: 15 de abril de 2026

Versão: 2.0

1. Sumário Executivo

Este relatório foca-se no problema central identificado na proposta original: a dependência operacional de múltiplos ficheiros Excel (Base Geral, propostas GMNF e registos de inibidores MEK) para gerir a jornada clínica de doentes com Neurofibromatose tipo 1. O modelo atual é frágil, duplica dados, dificulta auditoria e não permite alarmística automática.

A estratégia de migração adotada é assíncrona e em dois momentos distintos: uma importação inicial única que traz todo o histórico dos Excel para a base de dados central, e uma importação final de encerramento imediatamente antes de os ficheiros Excel serem arquivados definitivamente. Entre esses dois momentos, a equipa continua a trabalhar nos Excel — mas em paralelo o sistema central já está ativo para novos registos através de formulários web. Não existe sincronização contínua nem monitorização em tempo real dos ficheiros.

Um princípio central de proteção de dados atravessa todo o projeto: durante as fases de desenvolvimento e prova de conceito, os dados pessoais dos doentes são pseudonimizados — substituídos por dados fictícios gerados automaticamente. O mapeamento entre identidades reais e pseudónimos é mantido num ficheiro de chaves encriptado, exclusivamente na posse dos médicos responsáveis. Apenas na fase de adoção plena, após validação clínica e auditoria RGPD, os dados reais são restaurados na base de dados de produção.

São apresentadas três alternativas de implementação — (A) solução AI customizada, (B) stack open source auto-alojada, (C) solução cloud gerida — com comparação das suas características técnicas, vantagens e desvantagens.

2. Diagnóstico do Uso Atual de Excel

2.1. Problemas concretos observados

- Duplicação: o mesmo doente é inserido na Base Geral, no ficheiro GMNF e no ficheiro de monitorização MEK, com campos frequentemente divergentes entre si.
- Ausência de chave única: identificação por nome, número de processo ou data de nascimento, sem validação; erros de digitação geram registos duplicados e inconsistentes.
- Bloqueios de escrita: apenas um utilizador pode editar de cada vez; versões divergentes circulam por email.
- Sem trilha de auditoria: não se sabe quem alterou o quê nem quando; impossível cumprir RGPD em auditoria formal.
- Sem alarmística: exames em atraso, perda de seguimento e resultados críticos dependem exclusivamente da memória da equipa.
- Risco de perda: ficheiros em drives pessoais ou pastas partilhadas sem cópia de segurança formal.

2.2. Objetivo da migração

O objetivo não é uma transição instantânea. É criar um período de coexistência controlada: o Excel continua em uso durante a fase de construção do sistema, mas num momento claramente definido deixa de ser a fonte de verdade e é arquivado. A abordagem assíncrona evita a complexidade técnica de manter sincronização contínua e elimina o risco de conflitos de dados entre os dois sistemas.

3. Modelo de Migração Assíncrona

O modelo assenta em dois eventos de importação pontuais, separados por um período de coexistência. Não existe monitorização contínua dos ficheiros Excel durante este período. A pseudonimização dos dados pessoais está presente desde o primeiro evento de importação e é revertida apenas no evento final, após validação clínica completa.

3.1. Importação Inicial (Evento 1)

Executada uma única vez no arranque do projeto, antes de o sistema central estar disponível à equipa. O objetivo é carregar todo o histórico clínico existente nos Excel para a base de dados.

Como se faz

1. Inventariar todos os ficheiros Excel: nome, localização, número de linhas e colunas relevantes.
2. Construir um script de importação em Python (pandas + openpyxl) que normaliza os dados: limpa espaços, resolve duplicados por número de processo, converte datas e codifica campos categóricos.
3. Executar o script num ambiente de teste com uma cópia dos Excel. Validar a qualidade dos dados importados (comparação de contagens, revisão de uma amostra aleatória com a equipa clínica).
4. Executar o script em produção. Registrar data e hora exata da importação — este é o ponto de corte histórico.
5. Congelar os Excel como referência (read-only) a partir deste momento, para não criar divergências durante a fase de coexistência.

Pontos críticos

- Deduplicação: o maior risco é a existência do mesmo doente com grafias diferentes do nome ou com números de processo inconsistentes entre ficheiros. O script deve usar correspondência fuzzy (p. ex. biblioteca rapidfuzz) e apresentar à equipa os casos ambíguos para resolução manual antes da importação final.
- Consentimento: apenas os doentes com consentimento informado válido devem ser importados para a base de dados de produção. Os restantes ficam num registo separado, pendente de regularização.
- Rastreabilidade: cada linha importada deve registar a sua fonte original (nome do ficheiro, folha, linha) para possibilitar auditoria futura.

3.2. Período de Coexistência

Após a importação inicial, o sistema central entra em funcionamento para novos registos — decisões GMNF, tratamentos MEK, novos doentes — através de formulários web. Os Excel ficam congelados como arquivo do histórico. A equipa deixa de escrever nos Excel; toda a escrita nova é feita no sistema.

A duração deste período é definida pela própria equipa clínica, com base na sua confiança no sistema e na completude dos dados. Termina quando a equipa estiver pronta para avançar para a importação final e o restauro dos dados reais.

Durante este período não há qualquer sincronização automática entre o Excel e a base de dados. Se surgir informação histórica que faltou na importação inicial (p. ex. um ficheiro que não foi encontrado), essa correção é feita manualmente no sistema central, com registo de quem a fez e porquê.

3.3. Importação Final de Encerramento (Evento 2)

Imediatamente antes de os ficheiros Excel serem arquivados definitivamente, executa-se uma segunda importação para capturar qualquer atualização que tenha ocorrido nos Excel durante o período de coexistência (p. ex. correções manuais ao histórico que a equipa tenha feito diretamente no ficheiro antes de o fechar).

Como se faz

6. Correr o mesmo script de importação em modo diferencial: compara o estado atual do Excel com o estado na data de corte da importação inicial e importa apenas as linhas novas ou alteradas.
7. A equipa clínica revê o relatório de diferenças antes de confirmar a importação final.
8. Após confirmação, os ficheiros Excel são movidos para uma pasta de arquivo institucional (read-only, com controlo de acesso) e removidos das partilhas de trabalho.
9. O sistema central é declarado a única fonte de verdade a partir desta data.

3.4. Visão geral do processo

Importação Inicial (Evento 1)	Todo o histórico Excel entra na base de dados; Excel fica read-only	Pseudonimizados — dados fictícios
Período de Coexistência	Novos registos entram pelo sistema; Excel serve de arquivo histórico	Pseudonimizados — dados fictícios
Importação Final (Evento 2)	Diferenças residuais do Excel são importadas; Excel é arquivado	Pseudonimizados até restauro final
Restauro e produção plena	Dados reais substituem os pseudónimos; sistema é a única fonte de verdade	Dados reais restaurados

4. Plano de Implementação por Fases

O projeto organiza-se em cinco grandes fases sequenciais. Cada fase tem entregáveis concretos que devem ser validados pela equipa clínica antes de avançar para a seguinte.

Fase 1 — Diagnóstico e Auditoria

Objetivo: conhecer em detalhe o que existe hoje, antes de construir qualquer coisa. Esta fase produz o mapa completo do estado atual, o modelo de dados do sistema futuro, e — como primeiro passo imediato — uma estratégia concreta para que os médicos possam proteger os dados pessoais dos doentes desde o início, sem depender da equipa técnica para o fazer. O uso dos ficheiros Excel não é alterado durante esta fase.

Nota 1 — Estratégia imediata de proteção de dados pelos médicos

Antes de qualquer partilha de informação com a equipa técnica, os médicos devem dispor de um método simples para substituir os dados pessoais dos doentes por equivalentes fictícios nos ficheiros Excel. Este processo — que os médicos controlam de forma autónoma — garante que nenhum dado

identificável é transmitido para fora do ambiente clínico durante as fases de diagnóstico e desenvolvimento.

São propostas duas alternativas para realizar esta pseudonimização de forma prática:

Alternativa 1A — Ferramentas open source (opção preferencial)

Para volumes maiores ou para automatizar o processo sobre ficheiros Excel inteiros, podem usar-se ferramentas open source em combinação, sem enviar dados para qualquer serviço externo. Todo o processo corre no computador do médico ou num servidor interno do IPO. O output é o ficheiro com os dados substituídos e um ficheiro de mapeamento encriptado que o médico guarda na sua posse. São recomendadas as seguintes ferramentas:

- Microsoft Presidio — analisa texto ou tabelas e identifica automaticamente entidades pessoais (nomes, datas, números de identificação, contactos) usando modelos de reconhecimento de entidades nomeadas. Disponível como aplicação local ou serviço interno. Combina-se com a biblioteca Faker, que gera dados fictícios plausíveis em português para substituir cada entidade identificada.
- Google Cloud DLP (Data Loss Prevention) — pode ser utilizado em modo local ou via API privada para detetar e anonimizar automaticamente dados pessoais em texto, tabelas e ficheiros. Oferece deteção de entidades específicas do contexto europeu (números de identificação portugueses, IBAN, NIF) e permite configurar regras de substituição à medida.
- ARX Data Anonymization Tool — ferramenta open source especializada em anonimização e pseudonimização de conjuntos de dados tabulares, com suporte a múltiplos modelos de privacidade (k-anonimato, l-diversidade, t-proximidade). Adequada para anonimizar os ficheiros Excel de forma sistemática, com interface gráfica que não requer programação.

Alternativa 1B — Assistente de IA (Claude ou ChatGPT)

Para casos pontuais ou documentos de texto livre, um assistente de IA pode ser utilizado diretamente pelos médicos. O médico copia o conteúdo para a interface do assistente e solicita a substituição dos dados identificáveis por equivalentes fictícios, mantendo a estrutura e o significado clínico.

Exemplo de instrução ao assistente: "Substitui todos os nomes, datas de nascimento, números de processo, moradas e contactos neste texto por dados fictícios plausíveis. Mantém a estrutura dos campos e o conteúdo clínico intactos. Devolve uma tabela com o mapeamento original → fictício para eu guardar."

O assistente devolve o conteúdo pseudonimizado e a tabela de mapeamento, que o médico guarda localmente de forma segura. Esta abordagem é adequada para volumes pequenos mas não é a opção preferencial para processar ficheiros Excel completos.

Nota 2 — O Excel continua em uso normal durante esta fase

Nesta fase não se altera nada no modo de trabalho da equipa. Os ficheiros Excel continuam a ser editados normalmente por todos os utilizadores habituais. O único procedimento novo é que, sempre que for necessário partilhar dados com a equipa técnica — para análise do esquema de colunas, mapeamento ou testes — essa partilha é feita sobre uma versão pseudonimizada produzida pelos médicos com uma das ferramentas acima. Os ficheiros originais com dados reais permanecem exclusivamente no ambiente clínico.

Restantes micro-passos da Fase 1

- Inventariar todos os ficheiros Excel em uso: nome, localização, responsável, número de registos e data da última atualização.

- Entrevistar a equipa clínica sobre o fluxo real de trabalho: quem edita o quê, em que momento e com que frequência.
- Mapear a jornada do doente de ponta a ponta — da primeira consulta ao arquivo — identificando todos os pontos onde se produz ou consome informação clínica.
- Catalogar os tipos de documentos que entram no processo: relatórios de imagiologia, resultados de patologia, notas de consulta, propostas do GMNF, registos de inibidores MEK.
- Identificar os campos obrigatórios de cada ficheiro Excel e distingui-los dos campos de texto livre não estruturado.
- Mapear o esquema de colunas dos três ficheiros Excel para um modelo de dados relacional unificado, resolvendo conflitos de nomenclatura e de tipagem entre ficheiros.
- Definir a chave primária única do doente (número de processo IPO ou SNS) e as regras de deduplicação entre os três ficheiros.
- Identificar os doentes sem consentimento informado válido e definir o processo de regularização.
- Documentar os requisitos de alarmística: que alertas existem hoje de forma informal e que alertas críticos estão em falta.
- Envolver o Encarregado de Proteção de Dados (DPO) do IPO desde o início e iniciar a Avaliação de Impacto sobre a Proteção de Dados (DPIA) se aplicável.
- Produzir o Relatório de Diagnóstico com as lacunas identificadas, o modelo de dados proposto e a decisão sobre a alternativa de implementação a adotar.

Fase 2 — Prova de Conceito

Objetivo: validar as decisões técnicas e o modelo de dados com um subconjunto real de doentes, antes de comprometer esforço com o sistema completo. O protótipo deve ser funcional o suficiente para a equipa clínica o conseguir avaliar de forma crítica. Todos os dados pessoais estão pseudonimizados durante esta fase.

Pseudonimização dos dados pessoais

Antes de qualquer importação para o ambiente de desenvolvimento ou piloto, o script de importação aplica um processo de pseudonimização automática aos dados pessoais dos doentes. Este processo funciona da seguinte forma:

10. O script gera um identificador interno único e opaco para cada doente (por exemplo, um UUID), que se mantém constante ao longo de todo o projeto e em todos os ambientes.
11. Os campos de identificação direta — nome, data de nascimento, número de telefone, morada e outros dados que permitam identificar o doente — são substituídos por valores fictícios gerados de forma determinista a partir do UUID.
12. O número de processo IPO/SNS é substituído por um código interno derivado do UUID, garantindo que os registos permanecem associáveis internamente sem expor o identificador real.
13. O mapeamento entre os dados reais e os pseudónimos é guardado num ficheiro de chaves encriptado (AES-256), separado da base de dados do sistema e exclusivamente na posse dos médicos responsáveis pelo projeto. Este ficheiro nunca é partilhado com a equipa de desenvolvimento.
14. Em nenhum momento da Fase 2 ou da Fase 3 a equipa técnica tem acesso a dados pessoais reais. Toda a construção, teste e validação do sistema é feita sobre os pseudónimos.

Este modelo segue o princípio de pseudonimização definido no artigo 4.º do RGPD e garante que, mesmo em caso de acesso não autorizado ao ambiente de desenvolvimento, os dados pessoais dos doentes não são comprometidos.

Micro-passos da Fase 2

- Selecionar um subconjunto representativo de doentes para o piloto, cobrindo diferentes perfis clínicos e terapêuticos.
- Construir o script de importação assíncrona (Evento 1) com pseudonimização integrada e executá-lo sobre os dados do subconjunto para popular a base de dados do piloto.
- Montar a base de dados central com o esquema relacional definido na Fase 1 e validar a integridade dos dados importados com a equipa.
- Desenvolver um formulário web simples para registo de uma decisão do GMNF e testar o fluxo de ponta a ponta com utilizadores reais.
- Desenvolver o painel de visualização cronológica do doente, mostrando a sequência de consultas, decisões do GMNF, exames e terapêutica.
- Configurar pelo menos duas regras de alarmística representativas (por exemplo: exame periódico em atraso; doente sem registo de consulta no período esperado pelo protocolo).
- Testar o módulo de NLP sobre um conjunto de relatórios clínicos reais devidamente pseudonimizados, avaliar a qualidade da extração de entidades e identificar as lacunas.
- Apresentar o protótipo à equipa clínica em sessão de demonstração, recolher feedback estruturado e documentar os ajustes necessários.
- Validar com o DPO que o modelo de consentimento informado está corretamente implementado no fluxo de registo antes de avançar.
- Decidir formalmente o avanço para a Fase 3 com base nos resultados do piloto.

Fase 3 — Utilização Híbrida

Objetivo: colocar o sistema em produção para novos registos, mantendo os ficheiros Excel congelados como arquivo histórico. Nesta fase, os dois sistemas coexistem de forma controlada: o Excel serve de referência histórica read-only; todos os novos dados entram pelo sistema central.

- Executar a importação inicial completa (Evento 1) de todos os doentes com consentimento informado válido.
- Congelar os ficheiros Excel em modo read-only e comunicar formalmente à equipa a data de corte.
- Ativar os formulários web para todos os tipos de registo: novas decisões do GMNF, registo de inibidores MEK, novos doentes, eventos adversos e resultados de exames.
- Ativar o módulo de consentimento informado no fluxo de registo, impedindo que qualquer doente entre no sistema sem validação ética.
- Ativar o motor de alarmística para toda a população de doentes importada e monitorizar os primeiros alertas gerados.
- Disponibilizar o painel clínico à equipa como ferramenta principal de consulta e acompanhamento longitudinal dos doentes.
- Realizar sessões de formação prática com médicos e enfermeiros, focadas nos fluxos mais frequentes (registo pós-GMNF, monitorização MEK, resposta a alertas).
- Monitorizar a taxa de adoção: percentagem de novos registos feitos no sistema versus tentativas de editar os Excel. Identificar e resolver resistências.

- Ativar o NLP sobre os novos relatórios clínicos que entram no sistema, com revisão humana de cada sugestão antes de ser confirmada no processo do doente.
- Resolver erros, lacunas de dados e pedidos de ajuste de interface identificados em uso real.
- Recolher métricas de qualidade: alertas gerados, taxa de confirmação das sugestões NLP, registos em falta identificados pelo sistema.

Fase 4 — Adoção Plena e Retirada do Excel

Objetivo: encerrar definitivamente o uso dos ficheiros Excel, restaurar os dados pessoais reais na base de dados de produção, arquivar os ficheiros de forma segura e declarar o sistema central como única fonte de verdade do NF-IPO Lisboa.

- Executar a importação final diferencial (Evento 2): comparar o estado atual dos Excel com o estado na data de corte da Fase 3 e importar apenas as linhas entretanto corrigidas, mantendo ainda os dados pseudonimizados.
- A equipa clínica revê o relatório de diferenças gerado pela importação diferencial e confirma ou rejeita cada alteração antes de esta ser persistida.
- Restauro dos dados pessoais reais: após validação clínica completa do sistema, os médicos responsáveis utilizam o ficheiro de chaves (exclusivamente na sua posse) para executar o script de des-pseudonimização. Este script substitui, registo a registo, os valores fictícios pelos dados pessoais reais correspondentes, usando o UUID como chave de cruzamento. O UUID mantém-se como identificador interno permanente do doente no sistema.
- Verificar a integridade do restauro: confirmar que todos os UUIDs foram corretamente associados e que nenhum campo pessoal ficou por restaurar. Esta verificação é feita pelos médicos responsáveis sobre uma amostra aleatória de processos.
- Após confirmação do restauro, o ficheiro de chaves de pseudonimização é arquivado de forma segura (encriptado) e removido dos sistemas de trabalho — passa a existir apenas como cópia de segurança institucional sob custódia médica.
- Mover os ficheiros Excel para a pasta de arquivo institucional, com controlo de acesso restrito e cópia de segurança formal garantida pela infraestrutura do IPO.
- Remover os ficheiros das partilhas de trabalho e revogar permissões de edição a todos os utilizadores.
- Realizar a auditoria RGPD formal dos dados migrados: verificar rastreabilidade de origem, completude dos consentimentos e ausência de dados pessoais fora da base de dados autorizada.
- Emitir a comunicação formal à equipa clínica e à direção do IPO declarando o sistema central como única fonte de verdade a partir dessa data.
- Encerrar o período de suporte intensivo e transitar para o modo de manutenção corrente.

Fase 5 — Consolidação, Investigação Clínica e Expansão

Objetivo: transformar o sistema operacional num ativo de investigação clínica e expandir as suas capacidades à medida que a equipa ganha maturidade com a plataforma.

- Exportar datasets anonimizados e estruturados para investigação clínica, cumprindo os requisitos de anonimização definidos pelo DPO e pelo comité de ética.
- Ligar o sistema ao SClínico via protocolo FHIR, permitindo importar automaticamente resultados de análises, relatórios de imagiologia e outros eventos clínicos sem intervenção manual.

- Refinar o modelo de NLP com o corpus anotado acumulado durante as Fases 3 e 4, aumentando a precisão da extração de entidades específicas de NF1 em português clínico.
- Expandir o motor de alarmística com novas regras definidas pela equipa clínica a partir da experiência acumulada — por exemplo, alertas baseados em padrões de crescimento tumoral ou em combinações de eventos adversos.
- Desenvolver módulos de relatório automático para suporte a publicações científicas: tabelas de caracterização da coorte, curvas de seguimento, análise de resposta terapêutica.
- Avaliar a extensão do sistema a outras patologias raras seguidas no IPO, reutilizando a infraestrutura construída para o NF-IPO como base.
- Rever anualmente o modelo de dados e as regras de alarmística à luz de novas guidelines internacionais de NF1.

5. Três Alternativas de Implementação

Cada alternativa cumpre os mesmos requisitos funcionais: importação inicial e final assíncrona dos Excel, base de dados central única, formulários web para novos registos, alarmística, NLP para processamento de relatórios clínicos, e painel de validação médica. Diferem no modelo tecnológico, no grau de controlo sobre os dados e no esforço operacional.

5.A. Alternativa A — Solução Customizada

Descrição

Sistema desenhado e construído à medida para o NF-IPO Lisboa, combinando componentes open source maduros com um motor de NLP baseado em Large Language Models (LLMs) afinados para português clínico e para o vocabulário específico de Neurofibromatose. A solução pode ser implementada em infraestrutura própria do IPO ou em cloud (AWS ou Azure), conforme a política institucional e os requisitos de soberania dos dados.

O LLM lê relatórios de imagiologia, notas de consulta e resultados de patologia, extrai entidades clínicas (tipo de lesão, localização, tamanho, inibidor MEK, dose, evento adverso) e propõe atualizações ao processo do doente, que o médico valida num painel de decisão. Os modelos LLM recomendados, por ordem de preferência para português clínico, são Claude Opus 4.6 (Anthropic), GPT (OpenAI) e Llama (Meta).

Componentes

Importação Excel	Python + pandas + openpyxl + rapidfuzz	Scripts de importação assíncrona (Evento 1 e 2) com pseudonimização integrada
Orquestração	Apache Airflow	Gestão e monitorização dos pipelines de importação
Base de dados	PostgreSQL 16 + extensão pgvector	Dados estruturados e embeddings para NLP
NLP clínico	spaCy + medspaCy + LLM afinado (Claude Opus 4.6 / GPT / Llama)	Extração de entidades em português clínico; sugestões validadas pelo médico

Motor RAG	LangChain ou LlamaIndex	Pesquisa sobre protocolos e guidelines de NF1
Motor FHIR	HAPI FHIR server	Interoperabilidade com SClínico
API aplicacional	FastAPI	Serviços web para formulários e painel
Formulários web	React + React Hook Form	Registo de novos dados (GMNF, MEK, doentes)
Painel clínico	React + Metabase embutido	Visualização cronológica e alarmística
Alarmística	n8n (workflow engine)	Regras configuráveis sem código pela equipa
Autenticação	Keycloak	SSO integrado com Active Directory do IPO
Infraestrutura	On-premises do IPO ou AWS / Azure	Flexível conforme política institucional

Vantagens e desvantagens

- + Máxima adaptação ao NF-IPO: vocabulário, protocolos e alarmística 100% alinhados com a realidade do serviço.
- + Propriedade intelectual do IPO sobre o modelo e os dados; independência total de fornecedor de plataforma.
- + O corpus anotado gerado durante o projeto tem valor científico independente.
- + Flexibilidade de infraestrutura: pode correr on-premises, em AWS ou em Azure sem alterar a arquitetura aplicacional.
- + Sem lock-in de fornecedor; código auditável e modificável.
- – Esforço técnico elevado; requer equipa de desenvolvimento com competências em ML e DevOps, ou parceria académica sólida.
- – Risco regulatório (AI Act / MDR): se o sistema influenciar decisões clínicas, pode ser classificado como dispositivo médico de classe IIa — exige avaliação de conformidade.

5.B. Alternativa B — Solução Híbrida com EMR Open Source

Descrição

Em vez de construir um sistema de raiz, esta alternativa assenta na adoção de uma plataforma de Registo Clínico Eletrónico (EMR) open source já existente como espinha dorsal clínica, estendida com módulos específicos para NF1. O NF-IPO passa a beneficiar de funcionalidades clínicas já implementadas e validadas — formulários, histórico do doente, gestão de consultas, suporte a FHIR — sem ter de as construir do zero.

A migração dos dados Excel é feita através de um processo ETL (Extract, Transform, Load) em que a fase de Load utiliza uma estratégia de target delete: antes de cada carga, os registos existentes no destino são eliminados e substituídos pelos dados transformados. Esta abordagem garante idempotência — o processo pode ser repetido sem criar duplicados — e é especialmente adequada para os dois eventos de importação assíncrona definidos neste projeto.

Plataformas EMR open source consideradas

OpenMRS	Plataforma modular amplamente usada em contexto hospitalar; suporte nativo a FHIR R4; comunidade ativa; extensível com módulos clínicos específicos	Alta — base sólida para construir o módulo NF1
Bahmni	Distribuição hospitalar completa construída sobre OpenMRS; inclui gestão de doentes, consultas, resultados de laboratório e imagiologia; interface otimizada para clínicos	Alta — especialmente adequado se se pretender uma solução HIS completa
OpenEMR	EMR completo com módulos de prescrição, agendamento, relatórios e suporte a HL7/FHIR; interface web moderna; ativo em ambientes europeus	Média-alta — requer extensão para especificidades de NF1
GNU Health	Foco em saúde pública e doenças raras; modelo de dados rico para condições crónicas; suporte a SNOMED e ICD; desenvolvido com foco europeu	Média-alta — modelo de dados alinhado com doenças raras
MedBlocks	EMR moderno baseado em openEHR e FHIR; construído especificamente para extensibilidade clínica por formulários configuráveis sem código	Alta — permite modelar o percurso NF1 sem desenvolvimento à medida

Arquitetura ETL com target delete

O pipeline ETL para os dois eventos de importação assíncrona (Evento 1 e Evento 2) segue a seguinte lógica:

15. Extract: leitura dos ficheiros Excel pseudonimizados com pandas + openpyxl, produzindo um dataset normalizado em memória.
16. Transform: mapeamento dos campos Excel para o modelo de dados do EMR escolhido; resolução de conflitos; validação de consentimento; aplicação das regras de deduplicação.
17. Load (target delete): eliminação dos registos existentes no EMR para o conjunto de doentes a importar, seguida da inserção dos registos transformados. Esta estratégia garante que cada execução do pipeline produz um estado consistente, sem acumulação de versões parciais ou conflitos de atualização.

A orquestração do pipeline é feita com Apache Airflow, que regista cada execução com logs completos e permite repetir o processo de forma controlada.

Vantagens e desvantagens

- + Funcionalidades clínicas base já implementadas e testadas — menor risco de construção de raiz.
- + Suporte nativo a FHIR facilita a integração futura com SClínico.

- + A estratégia de target delete no Load garante idempotência e simplicidade operacional nos dois eventos de importação.
- + Comunidades ativas de suporte e desenvolvimento contínuo das plataformas.
- – Requer adaptação e extensão do EMR escolhido para o modelo de dados específico de NF1.
- – A interface do EMR pode não corresponder exatamente ao fluxo de trabalho da equipa do NF-IPO, exigindo configuração cuidadosa.
- – NLP e alarmística avançada têm de ser adicionados como módulos externos.

5.C. Alternativa C — Solução Cloud Gerida

Descrição

Assenta em serviços geridos de cloud, eliminando a necessidade de instalar ou manter servidores. São apresentadas duas sub-opções: Google Cloud (opção principal) e Microsoft Azure (opção alternativa, mais adequada se o IPO já dispuser de infraestrutura Microsoft e integração com SClínico).

Sub-opção C1 — Google Cloud (opção principal)

O Google Workspace permite migrar os ficheiros Excel para Google Sheets, que servem de ponto de partida para a importação assíncrona. A importação é feita via Google Sheets API — acionada manualmente nos dois momentos definidos (Evento 1 e Evento 2). Após o arquivo, os Sheets ficam em modo read-only no Google Drive institucional.

Armazenamento transitório	Google Sheets + Google Drive	Os Excel são convertidos para Sheets; servem de base para importação assíncrona
Importação assíncrona	Google Sheets API + Python (gsread)	Script lê os Sheets nos Eventos 1 e 2 e escreve na base de dados central
Base de dados	Cloud SQL para PostgreSQL (Google Cloud)	Fonte única de verdade
NLP clínico	Google Cloud Healthcare NLP API + Vertex AI (Gemini)	Extração de entidades clínicas em português
Interoperabilidade	Google Cloud Healthcare API (FHIR R4)	Conector com SClínico
Formulários e API	Cloud Run + FastAPI	Registo de novos dados (GMNF, MEK, doentes)
Painel clínico	Looker Studio + React em Cloud Run	Visualização cronológica e alarmística
Alarmística	Cloud Functions + Pub/Sub	Regras event-driven e notificações
Arquivo dos Sheets	Google Drive (acesso restrito)	Histórico read-only após encerramento

Segurança	Google Workspace Admin + Cloud IAM	SSO e controlo de acesso

Sub-opção C2 — Microsoft Azure (opção alternativa)

Mais adequada se o IPO já dispuser de Microsoft 365 institucional ou se existir integração com SClínico baseada em infraestrutura Microsoft. A importação assíncrona é feita via Azure Data Factory, acionado manualmente nos dois eventos de importação.

Importação assíncrona	Azure Data Factory + Azure Blob Storage	ETL para Evento 1 e Evento 2; Excel carregados manualmente para Blob
Base de dados	Azure Database for PostgreSQL (Flexible Server)	Fonte única de verdade
NLP clínico	Azure AI Language (Text Analytics for Health) + Azure OpenAI	Extração de entidades clínicas e sumarização
Interoperabilidade	Azure Health Data Services (FHIR R4)	Conector com SClínico
Formulários e API	Azure App Service + FastAPI	Registo de novos dados
Painel clínico	Power BI Embedded + React	Visualização cronológica e alarmística
Alarmística	Azure Functions + Event Grid	Regras event-driven e notificações
Segurança	Microsoft Entra ID + Purview	SSO, auditoria e governo de dados

Vantagens e desvantagens gerais da Alternativa C

- + Menor esforço de operação interna; serviços geridos pelo fornecedor.
- + Google Healthcare NLP e Azure AI Language for Health têm modelos clínicos em português com garantias de conformidade RGPD.
- + A migração de Excel para Google Sheets (C1) é simples e pode ser feita pela própria equipa.
- – Dados clínicos saem para infraestrutura de um fornecedor externo; requer DPIA e DPA formal.
- – Lock-in tecnológico elevado em ambas as sub-opções.

6. Comparação das Três Alternativas

Base clínica	Construída de raiz	EMR open source existente	Serviços Google Cloud	Serviços Azure
Importação assíncrona	Airflow + Python	Airflow + ETL target delete	Sheets API + Python	Azure Data Factory
LLM para NLP	Claude Opus 4.6 / GPT / Llama	Módulo externo adicionado	Gemini / Healthcare NLP	Azure OpenAI / AI Language
Controlo dos dados	Total (on-prem ou AWS/Azure próprio)	Total (on-prem ou AWS/Azure próprio)	Partilhado c/ Google	Partilhado c/ Microsoft
Interoperabilidade FHIR	HAPI FHIR próprio	Nativa no EMR	Google FHIR R4	Azure FHIR R4
Risco AI Act/MDR	Alto	Médio	Médio	Médio
Esforço operacional	Alto	Médio	Baixo	Baixo
Lock-in de fornecedor	Nenhum	Nenhum	Elevado	Elevado
DPIA com terceiros	Não necessário	Não necessário	Necessário (Google)	Necessário (Microsoft)

7. Recomendação

Para o NF-IPO Lisboa, recomenda-se a Alternativa B (EMR híbrida) como ponto de partida, com Bahmni ou OpenMRS como plataforma base, estendida com o módulo de NLP da Alternativa A usando Claude ou GPT como motor de extração clínica. A estratégia ETL com target delete simplifica a gestão dos dois eventos de importação assíncrona e garante consistência dos dados em cada execução.

A Alternativa A (solução customizada completa) é o objetivo de médio prazo: à medida que o corpus anotado crescer no IPO e a equipa ganhar maturidade com a plataforma, justifica-se acoplar um LLM afinado especificamente para NF1 em português — com Claude Opus 4.6 como opção preferencial pela sua capacidade de raciocínio clínico e suporte a português. A Alternativa C é recomendada apenas se existirem restrições institucionais que impeçam a manutenção de infraestrutura própria.

8. Próximos Passos Imediatos

18. Aprovação do plano de fases e do modelo assíncrono de migração pela direção clínica e de informática.
19. Inventário completo dos ficheiros Excel: localização, responsáveis, número de doentes e colunas (Fase 0).

20. Definição da chave primária única do doente e regras de deduplicação entre os três ficheiros Excel.
21. Mapeamento do esquema de colunas Excel para o modelo de dados relacional do sistema central.
22. Envolvimento do Encarregado de Proteção de Dados (DPO) do IPO para validar a estratégia de consentimento.
23. Desenvolvimento e validação do script de importação inicial (Evento 1) num ambiente de teste.
24. Execução da importação inicial em produção e comunicação à equipa do congelamento dos Excel.